Kitaptaki problem → Max Sub Sum

Kitaplar → Knuth Algorithm Book serisi (Donald Knuth), Data Structures and Algorithm Analyses in C++ (kitabın kodları kısa kod ile çok iş yapıyor, bizim takip edeceğimiz kitap bu), Robert Sedgewick'in kitabı.

* Machine Learning algoritmalarının (Logistic Regression, Random Forest ...) karmaşıklıkları. ML'de train ve test aşamasındaki karmaşıklıkları ayrılıyor.

P → S_1 ⋮ S_n } Time, memory → # command

recursive fibonacci
- → loop → n
- → recursive → 2^n

Time'ı ölçmek için 2 yöntem:
1) number of command
2) pc'ye zaman yaptırıyoruz

ignoring i

Elimizde bir problem var ve bu problem için 1'den fazla çözüm var. Bu çözümlerin time ve memorylerine bakacaz.

Analizde "Time"a bakıyoruz. Şimdilik memory 2. planda.

Zaman Karmaşıklığı Sınıfları ve P/NP Ayrımı

Algoritmaların büyüme hızlarını (growth rate) yani time complexity sınıflarıdır.

- C (Constant)
- log n
- n
- n log n
- n^2
- n^3
- n^4
- ⋮
- 2^n

} P, NP

Polinomsal Zaman (P):
- $O(1)$ → sabit zaman (constant / c)
- $O(\log n)$ → logaritmik
- $O(n)$ → doğrusal
- $O(n \log n)$ → doğrusal - logaritmik
- $O(n^2)$ → kareel
- $O(n^3)$ → kübik

Genel Form = $O(n^k)$ → polinomsal zaman

↳ Bunlar genellikle deterministik bir algoritma ile makul bir sürede çözülebilir problemler.

← Non-Deterministic Polinomsal Zaman (NP)
- $O(2^n)$

↳ Bu tip karmaşıklıklar üstel, çok hızlı büyür, pratikte büyük n için hesaplanamaz hale gelir.

NP için, çözüm bulmak polinomsal zamanda garanti değildir.

• ML'de karmaşıklık M.N ise M sütun N satır oluyor.

Asimptotik Gösterim

Bunlar büyüme sınırlarını ifade eder.

• O → * if else ; (Big-O) • Ω • Θ • o (little-o)

1) Big-O - Üst Sınır (Upper Bound)

• Algoritmanın en kötü durumda en fazla ne kadar büyüdüğünü gösterir.

"Bu algoritma en fazla $f(n)$ kadar büyür." → $O(f(n))$

Worst-case analizi temsil eder.

* $f(n) \leq c.g(n)$, $n > n_0$ → Bir fonksiyon keyfi bir sabit ile çarpıldığında sürekli büyük çıkıyorsa bu fonksiyona $f(n) = O(g(n))$ diyoruz.

$\underbrace{f(n)}_{n}$, $\underbrace{g(n)}_{n^2}$

$f(n) = O(\underbrace{g(n)}_{n^2})$

$n = O(n^2)$
$n = O(n^3)$
$n = O(n^4)$
⋮
$n^5 = O(n^5)$ → Direkt n^5 diyebiliriz. En mantıklı kendisine en yakın notasyonu almak.
n^6

$n^2 = O(n^2)$ — n, $n \log n$, n^2

$n^3 = O(n^3)$ — n, n^2, n^3, n^4, ⋮, 2^n → Bunun altındaki ifadeler olmaz.

2) Ω - Alt Sınır (Lower Bound)

• Algoritmanın en az ne kadar süreceğini gösterir.

"Bu algoritma en az $f(n)$ kadar zaman alır" → $O(f(n))$

Best-case veya teorik alt sınır olarak düşünülür.

* Ω : $f(n) \geq c.g(n)$, $n > n_0$ → Öyle bir fonksiyon var ki ondan sürekli aynı seviyede veya küçük oluyor.

$n = \Omega(n)$
$\log n$
c

Direkt eşit olması gerekiyor.

3) Θ - Sıkı Sınır (Tight Bound)

• Hem üst hem alt sınır aynı mertebedeyse kullanılır. Algoritma tam olarak bu büyüme mertebesindedir.

* $f(n) = O(g(n))$
  $g(n) = O(g(n))$
  $\Rightarrow f(n) = \Omega(n)$

$f(n) = \Theta(g(n))$
yani;
$f(n) = O(g(n))$ ve $f(n) = \Omega(g(n))$
(İkisi aynı anda sağlanmalı)

4) little - o - Sıkı Üst Sınır (Strict Upper Bound)

• Daha zayıf bir üst sınırdır.
Algoritma f(n)'den daha yavaş büyür.

$x = O(x^2)$ bir o

$x = o(x^2)$

$x^2 \neq o(x^2)$
aynı büyüklükte olmuyor.

* $f(n) < c \cdot g(n)$
$f(n) = o(g(n))$

$(\log(k))^n = o(n)$ ... little - o

Örnekler:

• $f(n) = n^2 + 5$, $g(n) = n + 7$ } $f(n) = \Omega(g(n))$ ✓, $f(n) = O(g(n))$ ✗

$n^2 + 5 \to n^2$ } $n^2 = O(n)$ ✗ , $n^2 = \Omega(n)$ ✓
$n = O(n^2)$ ✓

• $\underbrace{5n^2 + 6n + 3}_{n^2} = O(n^2), n^3, n^4 \ldots$
$\Omega(n^2), \underbrace{n, n\log n, \log n, c \ldots}$
ona kendisine en yakın olanı tercih ediyoruz.

n^2'ymiş gibi düşünüyoruz.

• $5n^2 + 6n + 3$ (vs) $6n^2 \to f(n) = \Theta(g(n))$

$5n^2 + 6n + 3 = O(6n^2)$
$5n^2 + 6n + 3 = \Omega(6n^2)$ > $5n^2 + 6n + 3 = \Theta(6n^2)$

$n \log n > n^2$

- $n\log n$, n^2 $\longrightarrow$ $n\log n = \Theta(n^2)$ ✗ → İkisi de aynı seviyede olmalı.
  $n\log n = O(n^2)$ ✓
  $n\log n = \Omega(n^2)$ ✗

- $2n^2+5$, $3n^3-20$ → $2n+5 = \Omega(3n^3-20)$ ✗
  $2n+5 = O(3n^3-20)$ ✓
  $2n+5 = \Theta(3n^3-20)$ ✗

* 2 fonksiyon ardışık olarak çağırıldığında toplanır:

$$\underset{f_1}{(n^2} + \underset{f_2}{n^3)} = O(n^3)$$

→ 2 algoritmayı birlikte ardışık çalıştırdıktan sonra karmaşıklığı direkt büyük olan alınır.

* 2 fonksiyon iç içe (nested) ise yani bir fonksiyon diğerinin içerisinde çağırılmışsa çarpılır:

$$\underset{f_1}{(n^2} \cdot \underset{f_2}{n^3)} = O(n^5)$$

→ Algoritmalar nested (iç içe) ise karmaşıklık ülker toplanı şeklinde (çarpım) bulunur.

Hoca 3 dedi bunu

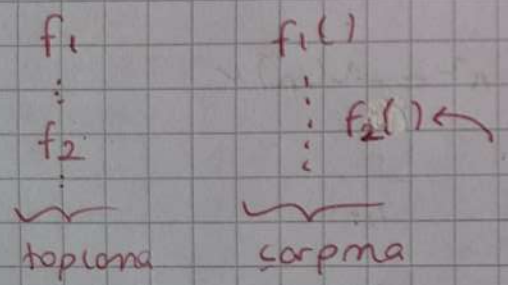

Her türlü karmaşıklığı büyük olan alınır.

2.4.1. Örnek Algoritma

$1^3+2^3+3^3+\dots+N^3$ toplamını hesaplayan kod:

```
int sum(int n){
    int partialSum; → Değişken tanımlama 0 zaman alır.
    partialSum = 0; → Atama işlemi 1 kez çalışır.
    for(int i=1; i≤n; ++i) → 2n+2
        partialSum += i*i*i; → 4n
    return partialSum; → 1 kez çalışır
}
```

* for (int i = 1; i ≤ n ; ++i) → Bu for döngüsünün 3 giriş maliyeti var:

a) Başlatma i=1 → Sadece 1 kez yapılır → 1 işlem

b) Test = i ≤ n kontrolü → Döngü her turda "devam et mi?" diye sorar

- N = 3 için: i=1 ✓, i=2 ✓, i=3 ✓, i=4 ✗ (dur)
- Yani N+1 kez test yapılır (son "hayır" testi de sayılır) → N+1 işlem

c) Arttırma: ++i → Her turda i'yi 1 arttırır, N kez yapılır → N işlem

↳ Toplam: $1 + (N+1) + N = 2N+2$

* partialSum += i * i * i

Bu satır döngünün içinde, N kez çalışır. Her çalışmada şu işlemler var:

i * i → 1 çarpma
(i * i) * i → 1 çarpma
partialSum + ... → 1 toplama
partialSum = ... → 1 atama

} Yani her turda 4 işlem, N tur → 4N işlem.

↳ Bütün çalışma toplamları → $6n+4$ → N çok büyük olduğunda +4 ve 6 katsayısı önemsiz olur. Geriye sadece n kalır. Yani karmaşıklık → O(n) olur. (1 tane döngü old. için n oldu.)

↳ Her seferinde bu kadar detaylı saymak gereksiz ve zor. Big-O kullanırken bazı kısayollar var:

- Sabit sayılar (4, 6) yok sayılır.
- Döngü olmayan satırlar önemsizdir.
- Sadece en baskın (en büyük büyüyen) terim önemlidir.

! Yani direkt döngü sayısına bakıp karmaşıklığı belirleyebiliriz.

• N çok büyüdükçe döngü dışındaki her şey küçücük kalır.

Durum	Örnek	Big-O
Döngü yok	sadece atama, return	O(1)
1 döngü	for i=1 to N	O(N)
İç içe 2 döngü	for i, for j içinde	$O(N^2)$
İç içe 3 döngü	for i, for j, for k içinde	$O(N^3)$

Örnek 2.4.1 için;

n defa dönüyor (6 → for bloğunda çalıştırdığı komut sayısı; 1 → for döngüsü)

+

$6n+4$ → O(n)

} 1 tane döngü old. için O(n) oldu.

Rule 1 - FOR Döngüleri (For Loops)

Bir for döngüsün çalışma süresi, döngü içindeki işlemlerin süresi çarpı kaç kez tekrarlandığıdır.

```
for (i=0 ; i<n ; ++i)
    ++k ;
```

→ n kez çalışır → $O(n)$

} Döngü içine bak, kaç kez dönüyorsa çarpılır

↳ for loops → $O(n)$, n

Rule 2 - İç İçe Döngüler (Nested Loops)

İçten dışa doğru analiz et. En içteki işlemin süresi, tüm döngülerin boyutlarının çarpımıdır.

```
for (i=0 ; i<n ; ++i)
    for (j=0 ; j<n ; ++j)
        ++k ;
```

→ $n * n = n^2$ kez → $O(n^2)$

} Kaç iç-içe döngü varsa, n'leri birbiriyle çarp.

↳ nested loops → $O(m.n)$, $m.n$

for ... → m → m kez dönüyor
⋮
for ... → n → n kez dönüyor
⋮

} diyelim

Rule 3 - Ardışık (Peş Peşe) Bloklar

Bunlar toplanır, yani en büyük olan kazanır.

```
for (i=0 ; i<n ; ++i)
    a[i] = 0 ;
for (i=0 ; i<n ; ++i)
    for (j=0 ; j<n ; ++j)
        a[i] += a[j] + i + j ;
```

} $O(n)$

} $O(n^2)$

} $\underbrace{O(n) + O(n^2) = O(n^2)}_{\text{Büyük olan değer alınır}}$

↳ consecutive (sequantial)

for ... } n.n
: for
for ... } n

} n^2

Rule 4 – If/Else

```
if(koşul)
    S1
else
    S2
```

Çalışma süresi, S1 ve S2'den hangisi daha uzun sürüyorsa odur. if ve else'ten daha yavaş olan hangisiyse onu al.

↳
```
if (koşul)
    O(n) iş
else
    O(n²) iş
```

En kötü ihtimale göre $O(n^2)$ denir.

↳
```
if
  : → S1
else
  : → S2
```

max(S1, S2)

- Bir if var ya da switch var. Hangisi büyükse onu al. En kötü olanına girmek yeterli.

$T(n)$ (n boyutlu problem çözülürken önce n-1 boyutlu problem çözülür sonra sabit maliyeti O(1) bir iş yapılır.

$\underbrace{\quad}_{T(n-1)}$

$$T(n) = 1 + T(n-1)$$
$$T(n-1) = T(n-2) + 1$$
$$T(n-2) = T(n-3) + 1$$
$$\vdots$$
$$+\ T(2) = T(1) + 1$$
$$T(n) = n \rightarrow O(n)$$

Telescoping method: Özellikle toplam veya yinelemeli (recurrence) ifadelerini sadeleştirmek için kullanılan matematiksel bir teknikdir. Terimler ardışık olarak birbirini götürür ve toplam büyük ölçüde sadeleşir.

* bir dizideki ardışık elemanlardan oluşan alt dizilerin arasında toplamı en büyük olanı bulma problemi için farklı çözümlerin karmaşıklıklarını karşılaştıralım.

↳ Algoritmada deneyeceğimiz diziyi "4, -3, 5, -2, -1, 2, 6, -2" olsun. Algoritmaların 11 sonucunu dönmesi gerekir.

↳ Maximum Subsequence Sum Problem

Algoritm 1

* Cubic maximum contiguous subsequence sum algoritm.

```
int maxSubSum1 (const vector<int>& a){
    int maxSum = 0;
    for(int i=0; i<a.size(); ++i)
        for(int j=i; j<a.size(); ++j){
            int thisSum=0;
            for (int k=i; k<=j; ++k)
                thisSum += a[k];
            if (thisSum > maxSum)
                maxSum = thisSum;
        }
    return maxSum;
}
```

Bu algoritmada 3 döngü olduğu için karmaşıklık $O(n^3)$'tür.

İç içe 3 döngü

Algoritm 2

* Quadratic maximum contiguous subsequence sum algoritm.

```
int maxSubSum2 (const vector<int>& a){
    int maxSum = 0;
    for (int i=0; i<a.size(); ++i){
        int thisSum=0;
        for(int j=i; j<a.size(); ++j){
            thisSum += a[j];
            if (thisSum > maxSum)
                maxSum = thisSum;
        }
    }
    return maxSum;
}
```

karmaşıklık $O(n^2)$ çünkü 2 tane for döngüsü var.

Algoritm 3

* Rewrsive maximum contiguous subsequence sum algoritm.
* Finds maximum sum in subarray spanning a[left ... right].
* Does not attempt to maintain actual best sequence.

Rewrsive algoritma. Diziyi ikiye bölüp uçlara kadar gidiyor.

karmaşıklığı:

$$T(n) = T(n/2) + T(n/2) + n$$
$$T(n) = 2T(n/2) + n$$
$$2 / \; T(n/2) = 2 \cdot T(n/4) + n/2 \quad \Big\} \; T(n) = 4T(n/4) + 2n$$
$$+ \; T(2) = 2 \cdot T(1) + n \rightarrow \text{recursion bitişi}$$

$$T(n) = O(n \log n)$$ → Algoritma 3 karmaşıklık olarak daha güzel bir yöntem diğerlerine göre.

Algoritma 4

* Linear-time maximum contiguous subsequence sum algoritma.

```
int maxSubSum4(const vector<int>& a){
    int maxSum=0, thisSum=0;
    for(int j=0; j<a.size(); ++j){
        thisSum += a[j];
        if(thisSum > maxSum)
            maxSum = thisSum;
        else if(thisSum < 0)
            thisSum = 0;
    }
    return maxSum;
}
```

Bir for döngüsü olduğundan zaman karmaşıklığı O(n)'dir.

En iyi karmaşıklığa sahip olan algoritma

Algoritma 3'ün karmaşıklık Açıklaması:

* algoritmada recurrence yazılır:
  - sol yarıyı çözer → $T(n/2)$
  - sağ yarıyı çözer → $T(n/2)$
  - ortayı kontrol eder → n

  Bu yüzden;
  $$T(n) = T(n/2) + T(n/2) + n$$
  $$T(n) = 2T(n/2) + n$$
  sadeleştir

* $n/2$ için ayrı formül yazılır:
  $$T(n/2) = 2T(n/4) + n/2$$

* yerine koyulur → $T(n/2)$:
  $$T(n) = 2(\underbrace{2T(n/4) + n/2}_{T(n/2)}) + n$$

* sadeleştirme:
  $$T(n) = 4T(n/4) + 2n$$

* tekrar açınca pattern oluşur:
  $$T(n) = 2^k T(n/2^k) + kn$$

baslangıç → dizi boyutu n

1. recursive = n/2
2. recursive = n/4
3. recursive = n/8

} k. recursive = $\underbrace{n/2^k}_{\text{alt problem boyutu}}$

* recursion bitişi :

her recursive çağrı dizinin bir parçası üzerinde çalışıyor. Bu parça artık tek eleman olunca :

alt problem boyutu ← $n/2^k = 1$

- $n = 2^k$
- $k = \log n$

$n \cdot n/2^k = 1 \cdot n \rightarrow 2^k = n$

$\hookrightarrow k = \log n$

* yerine koyma :

$$T(n) = \overset{2^k}{n}\, \underbrace{T(1)}_{T(n/2^k)} + n \underbrace{\log n}_{k}$$

$$T(n) = \underbrace{n + n\log n}_{\text{büyük olanı aldık yani } n\log n}$$

* Big-O :

$$T(n) = O(n \log n)$$